Actividad 5 | Entrenamiento y ajuste de modelos bancarios

Caso: prediccion de contratacion de depositos a plazo mediante regresion logistica y Random Forest. **Estado:** documento metodologico listo; los resultados numericos y las capturas de MLflow deben incorporarse despues de ejecutar el notebook en Google Colab. No se presentan resultados simulados como observados.

1. Contexto, objetivo y fuente

Se estudia la respuesta a campañas telefonicas de una entidad bancaria portuguesa. La variable objetivo y indica si el cliente contrato un deposito a plazo. Fuente: UCI Machine Learning Repository, Bank Marketing, variante bank-full.csv, 45.211 filas y 17 columnas originales. URL: https://archive.ics.uci.edu/dataset/222/bank+marketing. Los datos son historicos y no proceden de BBVA.

2. Diccionario de datos y supuestos

Variable	Significado
age, job, marital, education	Edad, ocupacion, estado civil, estudios
default, balance, housing, loan	Impago, saldo medio, hipoteca, prestamo
contact, day, month, campaign	Canal, dia/mes y numero de contactos
pdays, previous, poutcome	Historial de contacto y campaña previa
duration	Duracion de llamada: EXCLUIDA del modelo
y	Contratacion de deposito: yes/no

Supuesto operacional: se predice antes de la llamada; por ello duration provocaria fuga de informacion. Los valores unknown se tratan como categorias, no como ceros. El dataset no contiene identificadores individuales para deduplicacion de entidades.

3. Limpieza, estandarizacion y versionado

El script datos_prep.py descarga el archivo original desde UCI, verifica dimensiones y columnas, elimina duration, normaliza cadenas a minusculas, elimina filas exactamente duplicadas y transforma y en 0/1. Los datos originales y limpios se guardan en directorios separados. El escalado numerico, la imputacion y la codificacion OneHot se ajustan dentro de pipelines por fold para evitar fuga de informacion. Se documentan decisiones en README y CHANGELOG.

4. Visualizaciones exploratorias

El notebook genera una grafica de distribucion de la clase objetivo, una exploracion de valores extremos de balance, curvas ROC, matrices de confusion y una comparacion de metricas. Las figuras se guardan en graficas/ al ejecutar el entrenamiento. Su interpretacion debe basarse en las imagenes generadas, no en estimaciones previas.

5. Modelos e hiperparametros

Modelo	Configuraciones evaluadas
Regresion logistica	C = 0.1, 1, 10; class_weight = None, balanced
Random Forest	n_estimators = 100, 200; max_depth = 8, 16; min_samples_leaf = 1, 5

Se utiliza train_test_split estratificado 80/20 (random_state=42). En el 80% de entrenamiento se aplica GridSearchCV con StratifiedKFold de 5 particiones, seleccionando la mejor configuracion por F1. El conjunto de prueba se reserva para una sola evaluacion final.

6. Metricas y comparacion estadistica

Se registran accuracy, precision, recall, F1 y ROC-AUC en test, asi como media y desviacion estandar de F1 en 5 folds. La dispersion entre folds es descriptiva; con solo cinco folds no se afirma significacion estadistica de diferencias. Si se desea inferencia formal, debe definirse un protocolo adicional de comparacion pareada.

Metrica	Regresion logistica	Random Forest
Accuracy	Pendiente de ejecucion	Pendiente de ejecucion
Precision	Pendiente	Pendiente
Recall	Pendiente	Pendiente
F1	Pendiente	Pendiente
ROC-AUC	Pendiente	Pendiente
F1 CV media +/- DE	Pendiente	Pendiente

7. MLflow: evidencia y reproducibilidad

El script registra hiperparametros, metricas, matrices de confusion, curvas ROC y modelos en un backend local MLflow (mlruns/). El notebook inicia la interfaz MLflow en Colab para capturar las ejecuciones. **Evidencia pendiente:** capturas autenticas de la lista de runs, parametros, metricas y artefactos; no es posible acreditarlas sin ejecutar el notebook.

8. Reflexion sobre deuda tecnica y MLOps

El versionado de codigo, datos y modelos reduce deuda tecnica y facilita reproducibilidad. Riesgos: cambios de distribucion temporal, sesgos en variables demograficas, interpretacion erronea de predicciones como causalidad, falta de monitoreo, dependencia de un entorno efimero Colab y almacenamiento local de MLflow. Antes de produccion serian necesarios controles de equidad, privacidad, seguridad, monitoreo, aprobacion y validacion de negocio.

9. Conclusiones y acciones de cierre

El proyecto implementa un flujo reproducible de preparacion, entrenamiento, busqueda de hiperparametros y seguimiento de experimentos. La seleccion del modelo ganador solo podra justificarse tras ejecutar el notebook y revisar F1, ROC-AUC, recall, precision y dispersion de validacion. Para cerrar la entrega: ejecutar Colab, conservar resultados, obtener capturas MLflow, actualizar esta tabla con cifras reales y publicar en GitHub.

Referencia: Moro, S., Cortez, P. y Rita, P. (2014). A Data-Driven Approach to Predict the Success of Bank Telemarketing. Decision Support Systems, 62, 22-31. Dataset: UCI Bank Marketing (id 222).